TECNOLÓGICO NACIONAL DE MÉXICO
INSTITUTO TECNOLÓGICO DE COLIMA
Departamento de Sistemas y Computación

PROYECTO INTEGRADOR: PIPELINE ETL ROBUSTO CON ZONA DE CUARENTENA

Materia: Ingeniería de Datos (ATD-2602) | **Unidad 2:** Limpieza y Preprocesamiento de Datos
Modalidad: Equipos de 3 Personas | **Duración:** 1 Semana | **Ponderación:** 60% Portafolio Digital

1. Objetivo General del Proyecto

Diseñar, implementar y defender un **Pipeline ETL (Extract, Transform, Load)** end-to-end en Python que ingiera datos crudos y altamente inconsistentes de múltiples fuentes heterogéneas, diagnostique objetivamente su calidad, aplique técnicas estadísticas de preprocesamiento, valide estrictamente las reglas de negocio mediante **Pydantic** y persista los registros conformes en una base de datos relacional (SQLite o PostgreSQL), aislando automáticamente los registros inválidos en una **tabla de cuarentena** sin detener el procesamiento del lote.

> ***Principio de Robustez en Producción:*** *Un pipeline no se evalúa únicamente porque funcione en el caso ideal (happy path). Un verdadero pipeline de ingeniería se define por su capacidad de procesar registros corruptos, tipografías erróneas o llaves huérfanas* ***sin colapsar*** *(no crash), desviando la anomalía con trazabilidad auditable.*

2. Organización y Matriz de Responsabilidades (3 Integrantes)

Para garantizar un trabajo equitativo y evitar que una sola persona concentre la programación, cada equipo de 3 estudiantes debe asignar explícitamente los siguientes tres roles de ingeniería en su repositorio Git:

Rol / Especialidad	Responsabilidades Técnicas Específicas	Entregable Clave
Ingeniero/a 1 *Calidad, Nulos y Outliers*	• Perfilado inicial de calidad (completitud, unicidad, tipos). • Clasificación de faltantes (MCAR/MAR) e imputación estadística justificada. • Detección de outliers (IQR / Z-score) y aplicación de **Capping / Winsorizing** en importes y cantidades.	Funciones de limpieza + Reporte comparativo de calidad antes/después.
Ingeniero/a 2 *Transformación e Integración*	• Fusión de fuentes heterogéneas (CSV físico + JSON web/digital). • Resolución de discrepancias: unificación de fechas a YYYY-MM-DD y conversión de moneda (USD a MXN @ $19.50). • Cruce con catálogo maestro y detección de **registros huérfanos**. • Escalamiento Min-Max y discretización por reglas de negocio.	Módulo de integración multifuente y normalización de variables.
Ingeniero/a 3 *Validación, Resiliencia y BD*	• Modelado de clases BaseModel con **Pydantic** y @field_validator. • Mecanismo de segregación: registros aptos vs. **zona de cuarentena** con causa. • Inserción a base de datos con transacciones seguras (commit / rollback). • Batería de pruebas de estrés con inyección de datos corruptos.	Esquemas Pydantic + Script de carga a BD + Pruebas de estrés.

3. Datasets Oficiales Asignados por Grupo

Cada grupo vespertino trabajará con un sector industrial diferenciado, ubicado en la carpeta datasets/:

Grupo	Dominio de Datos	Archivos Suministrados	Retos Principales
Grupo 1 (LCS2)	**Retail & E-commerce Omnicanal** (Venta física + Tienda web)	• catalogo_productos.csv • ventas_tienda_fisica.csv • ventas_online.json	Duplicados de POS, fechas mixtas (DD/MM vs ISO), nulos en totales, precios en USD vs MXN, correos malformados y bots con compras gigantes.
Grupo 2 (LCNT)	**Fintech & Transacciones Bancarias** (Cajeros ATM + SPEI / App)	• catalogo_cuentas.csv • transacciones_atm.csv • transferencias_digitales.json	Reintentos de cajero, montos negativos absurdos, CLABEs con menos de 18 dígitos, cuentas huérfanas no registradas en Core Bancario y comisiones nulas.

4. Requisitos Técnicos Obligatorios (Las 6 Fases del Pipeline)

• **Fase 1: Diagnóstico de Calidad Inicial:** Ejecutar un perfilado cuantitativo de los datos crudos antes de cualquier transformación. Medir completitud (% de nulos por columna), unicidad (conteo de duplicados exactos) y tipos inferidos (dtypes).

• **Fase 2: Manejo de Faltantes e Imputación:** Clasificar las ausencias (MCAR o MAR). Imputar variables numéricas sesgadas con la **mediana** (justificar en el reporte por qué no la media). Imputar categóricas con etiquetas controladas (ej. 'ANONIMO'). Recalcular campos donde la información exista en otras columnas (ej. monto_total = cantidad * precio_unitario).

• **Fase 3: Tratamiento de Outliers con IQR (Capping):** Calcular el Rango Intercuartílico (IQR = Q3 - Q1) con factor 1.5. Aplicar **Winsorizing / Capping** para recortar los valores a los umbrales límite en lugar de eliminar filas arbitrariamente. Eliminar únicamente registros con valores imposibles (cantidades <= 0).

• **Fase 4: Integración, Unificación y Huérfanos:** Homologar todas las fechas a formato estándar ISO (YYYY-MM-DD). Convertir importes en USD a MXN a paridad oficial ($19.50). Realizar cruce (merge) contra el catálogo maestro y marcar transacciones con **llaves huérfanas** para desvío a cuarentena.

• **Fase 5: Transformación, Discretización y Escalamiento:** Normalizar la variable numérica mediante Min-Max en el rango [0, 1]. Discretizar el importe en 3 segmentos (Bajo, Medio, Alto) mediante cuantiles o reglas de negocio justificadas.

• **Fase 6: Validación con Pydantic y Cuarentena:** Definir esquemas estrictos con validadores personalizados. Los registros válidos se preparan para la tabla final. Los registros que violen el esquema se capturan en un bloque try...except ValidationError y se desvían a la lista de cuarentena, guardando la columna motivo_rechazo_cuarentena.

• **Fase 7: Carga Transaccional a Base de Datos:** Persistir los datos en SQLite o PostgreSQL mediante transacciones seguras (conn.commit() y conn.rollback()). Poblar dos tablas obligatorias: transacciones_limpias y cuarentena_errores.

5. Cronograma Semanal de Trabajo en Laboratorio

Día	Actividad en Clase de Laboratorio	Entregable Obligatorio
Día 1 (Lunes)	Encuadre, conformación de equipos de 3, lectura de datos crudos y diseño del diagrama de flujo (Mockup).	Archivo REGLAS_DE_NEGOCIO.md con justificación técnica firmada.
Día 2 (Martes)	Desarrollo de funciones de imputación de nulos, tratamiento de outliers con IQR e integración de fuentes.	Avance de código de limpieza y cruce multifuente en Git.
Día 3 (Miércoles)	Implementación de escalamiento/discretización y diseño de modelos de validación con Pydantic.	Módulo Pydantic y bifurcación a cuarentena operativa.
Día 4 (Jueves)	Conexión a Base de Datos SQLite/PostgreSQL, persistencia transaccional y pruebas de estrés con datos corruptos.	Pipeline end-to-end funcional corriendo de inicio a fin.
Día 5 (Viernes)	**Defensa Técnica Oral en Vivo (5 a 7 minutos por equipo)** frente al docente con preguntas individuales.	**Entrega final:** Repositorio Git + BD SQLite + Reporte PDF.

6. Rúbrica de Evaluación Oficial (Base 100 Puntos)

Conforme a la Instrumentación Didáctica oficial de la asignatura, este proyecto equivale al **60% del Portafolio Digital** de la Unidad 2:

Criterio Técnico	Pts	Estándar de Desempeño Excelente (100%)
1. Mockup y Reglas de Negocio	**10**	Diagrama de flujo completo; decisiones de limpieza justificadas estadísticamente en REGLAS_DE_NEGOCIO.md.
2. Calidad de Datos (Nulos y Outliers)	**20**	Imputación correcta según tipo de ausencia; outliers tratados mediante IQR / Capping sin pérdida destructiva de datos válidos.
3. Integración y Transformación	**20**	Cruce de fuentes heterogéneas, normalización de divisas (USD a MXN), estandarización de fechas, discretización y escalamiento Min-Max.
4. Validación Pydantic y Cuarentena	**20**	Modelos robustos con decoradores; separación limpia entre registros conformes y registros desviados a cuarentena con detalle de error.
5. Persistencia y Transacciones en BD	**15**	Carga a base de datos relacional con manejo seguro de transacciones (commit y rollback). Tablas íntegras y legibles.
6. Resiliencia y Defensa Oral	**15**	El pipeline soporta datos corruptos sin lanzar excepciones no controladas (*no crash*); dominio técnico individual de los 3 integrantes.
TOTAL CALIFICACIÓN	**100**	**Ponderación institucional: 60% Portafolio Digital de la Unidad 2.**